

Pseudoinversa de Moore-Penrose

Fundamentos, implementación numérica y matrices singulares

1. Definición y cálculo mediante SVD

La **pseudoinversa de Moore-Penrose**, denotada A^+ , es la generalización de la inversa clásica para matrices arbitrarias —rectangulares o singulares—. Se calcula mediante la **Descomposición en Valores Singulares (SVD)**, invirtiendo únicamente los valores singulares no nulos de A y transponiendo el resultado, mientras que los valores singulares nulos se mantienen como cero.

En computación numérica, los valores singulares menores a una **tolerancia** τ se tratan como cero para mejorar la estabilidad ante perturbaciones numéricas.

Fórmula fundamental

Si $A = U \Sigma V^T$, entonces:

$$A^+ = V \Sigma^+ U^T$$

donde Σ^+ es una matriz diagonal que contiene

$$\Sigma^+_{ii} = \begin{cases} 1/\sigma_i & \text{si } \sigma_i > \tau \\ 0 & \text{en caso contrario} \end{cases}$$

Componentes de la SVD en la pseudoinversa

Componente	Notación	Rol en la pseudoinversa
Matriz U	$U \ (m \times m)$	Vectores singulares izquierdos de A
	$\Sigma \ (m \times n)$	Diagonal con $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$
Matriz V	$V \ (n \times n)$	Vectores singulares derechos de A
	$\Sigma^+ \ (n \times m)$	$1/\sigma_i$ si $\sigma_i > \tau$, 0 en caso contrario

2. Implementación numérica (MATLAB / Octave)

La función `pinv` de MATLAB/Octave implementa la pseudoinversa con control automático de tolerancia. La elección correcta de τ es **crítica** para gestionar los valores singulares pequeños que surgen del ruido numérico en matrices mal condicionadas.

Tolerancia por defecto en MATLAB / Octave

$$\tau = \max(m, n) \cdot \sigma_{\max} \cdot \varepsilon_{\text{mach}}$$

donde $\varepsilon_{\text{mach}} \approx 2,22 \times 10^{-16}$ es el épsilon de la máquina en doble precisión IEEE 754.

```

1 % SVD y pseudoinversa manual con tolerancia personalizada
2 [U, S, V] = svd(A); % Descomposicion SVD
3 [m, n] = size(A);
4 tol = max(m,n) * eps(norm(S,inf)); % Tolerancia adaptativa
5
6 % Invertir solo los valores singulares mayores que tol
7 s = diag(S);
8 s_inv = zeros(size(s));
9 s_inv(s > tol) = 1 ./ s(s > tol);
10
11 S_plus = zeros(n, m); % Sigma^+ transpuesta (n
    x m)
12 S_plus(1:length(s_inv), 1:length(s_inv)) = diag(s_inv);
13
14 A_plus = V * S_plus * U'; % A^+ = V Sigma^+ U^T
15
16 % Forma compacta equivalente (usa la misma tolerancia interna)
17 A_plus2 = pinv(A);

```

Listing 1: Pseudoinversa manual con tolerancia personalizada (MATLAB/Octave)

3. Matrices singulares y solución de norma mínima

Para matrices que **no son de rango completo** (singulares o rectangulares), la inversa clásica no existe. La SVD proporciona una manera robusta de encontrar una **solución de norma mínima** al sistema $Ax = b$:

$$x^* = A^+ b \quad \implies \quad \|x^*\| = \min\{\|x\| : Ax = b\}.$$

Las cuatro condiciones de Moore-Penrose

Propiedad	Expresión	Descripción
Consistencia	$AA^+A = A$	A^+ es inversa débil de A
	$A^+AA^+ = A^+$	A^+ también satisface la condición débil
Hermiticidad ¹	$(AA^+)^H = AA^+$	El producto AA^+ es Hermítico
	$(A^+A)^H = A^+A$	El producto A^+A es Hermítico

Aplicaciones típicas

- **Sistemas sobredeterminados** ($m > n$): mínimos cuadrados lineales — regresión, ajuste de curvas.
- **Sistemas subdeterminados** ($m < n$): solución de norma mínima entre infinitas soluciones posibles.
- **Control y robótica**: cinemática inversa de robots redundantes (jacobiana pseudoinversa).
- **Procesamiento de señales**: filtros óptimos, deconvolución, compresión SVD de imágenes.
- **Machine learning**: regresión ridge (regularización de Tikhonov) y redes neuronales de capa única (ELM).

△ Nota sobre estabilidad numérica

Cuando la matriz A está mal condicionada ($\kappa(A) = \sigma_{\max}/\sigma_{\min} \gg 1$), pequeñas perturbaciones en los datos producen grandes variaciones en A^+ . En estos casos se recomienda emplear **regularización de Tikhonov**:

$$A_{\lambda}^+ = (A^T A + \lambda I)^{-1} A^T,$$

eligiendo λ mediante la *curva-L* o la validación cruzada generalizada (GCV).